

2025-1데이터마이닝 방법 및 실습 프로젝트

재무정보를 활용한 한국 기업의 부도 예측

Team1 | 강병조 서정호 오지인 홍인택




Table of Contents

1. 서론
2. 데이터 소개
3. 전처리 과정
4. 부도여부 예측
5. 부도확률 예측
6. 전체 Feature 분석
7. 결론

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

주제: 재무제표를 활용한 한국 기업의 부도/파산 여부 예측

1

“재무정보를 활용한” 기업의 부도/파산에 관련한 기존의 연구가 실제 데이터에서 타당한지 검증하고자 함

- 시장 요인보다 재무정보가 실무 의사결정에 더 중요하다고 판단
- 한국 상장기업 대상, 1999~2024년 데이터 활용
- IMF, 금융위기, 코로나 등 포함해 경제 충격에도 강건한 모형 구축 목표

2

재무정보와 부도/파산여부, 부도/파산확률 간 관계를 모두 확인하고자 함

- 불균형·중도 절단(censored) 데이터 문제 고려
- 복잡하지 않으면서도 실효성 있는 예측 모형 설계 지향

초기 Proposal 대만 기업 파산 데이터(교육용)에서 더욱 광범위하고 직접적으로 유의미한 한국 기업 데이터 사용

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

데이터 설명

Dataguide | 1999년~2024년 한국 기업의 연간 재무제표 및 기타 기업 정보 데이터

- 코스피/코스닥에 상장된 적 있는 모든 기업을 대상으로 함

KIND 전자공시시스템 | 1999년~2024년 코스피/코스닥 상장기업의 상장폐지일자, 폐지사유

- Dataguide 데이터에는 부도/파산여부가 직접적으로 나와 있지 않기 때문에 독립변수를 가공하여 직접 만들기 위함
- 1999년 이후의 데이터가 제공되기 때문에, 분석기간은 가능한 최대 기간인 1999년부터로 설정

전처리 전 병합하여 만든 최종 데이터는 약 15만 행, 6271개 기업

재무제표 변수 255개	종목코드	회사명	결산월	회계년	주기	상장폐지일자	폐지사유	독립변수 관련 4개열
--------------	------	-----	-----	-----	----	--------	------	-------------

총 265개 열

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

전처리 과정: 종속변수

- 수집 가능한 데이터는 부도/파산여부가 아니라 상장폐지 및 그 사유이나, 상장폐지 그 자체로는 부도/파산 여부를 판단할 수 없음
- 상장기업의 경우, 부도/파산이 일어나면 무조건 상장폐지된다는 점을 활용하여 아래와 같이 정의함



- 실제로 상장폐지(부도, 파산)가 일어난 해에만 1로, 그 이전 해에는 0으로 처리
- 만약 부도, 파산이 일어난 해의 재무제표 데이터가 아예 없을 경우, 가장 가까운 해의 종속변수를 1로 처리
- 상장폐지 후 다시 회생된 경우 첫 상장폐지 이후 해당 기업의 데이터 삭제
- Duration: 생존기간. 즉 해당 연도까지 해당 기업의 데이터가 수집된 기간

전처리 과정: 독립변수 (변수 추출)

■ 선행연구¹⁾를 바탕으로 총 14개 재무비율을 아래와 같이 선정하였음

- | | | |
|--------------------------------------|---------------------|--------------------------|
| • 금융비용/부채 | • 영업이익/총자본 | • 총부채회전율 = 매출액/총부채 |
| • 금융비용/총비용 | • 유보이익/총자본 | • 총자본투자효율 = 영업이익/총자산 |
| • 설비투자효율
= (영업이익 + 감가상각) / (유형자산) | • 자기자본비율 = 자기자본/총자산 | • 총자본회전율 = 매출액/총자산 |
| • 현금흐름/총자본 | • 자본금회전율 = 매출액/자본금 | • 총순자산수익률 = 당기순이익/자기자본 |
| | • 차입금의존도 = 차입금/총자산 | • 현금성자산비율 = 현금및현금성자산/총자산 |

■ 재무비율을 구하기 위한 지표들을 파악하였을 때, 재무제표에서 직접 제공이 되지 않아 가공이 필요한 지표는 아래와 같음

- | | |
|-----------------------|--------------------------------|
| • 차입금 = 단기차입금 + 장기차입금 | • 총비용 = 매출원가 + 판매비와관리비 + 비영업비용 |
| • 운전자본 = 유동자산 - 유동부채 | • EBITDA = 영업이익 + 유무형자산상각비 |

전처리 과정: 독립변수 (결측치 처리)

- 결측치가 확인되어 검토가 필요한 지표 계정들은 다음과 같음


유동자산	6448
유동부채	6448
장기차입금	6448
단기차입금	6448
매출원가	2895
유보액	32
총자산	11
현금및현금성자산	11
총부채	11
총자본	11
자본금	11
유형자산	11
이익잉여금	11

- 재무제표의 구성상 타 계정의 합산으로 구할 수 있는 계정은 직접 계산하여 다음과 같이 처리함

- 유동자산** = 현금및현금성자산 + 단기금융상품 + 단기유가증권 + 단기대여금 + 매출채권 + 단기미청구공사 + 재고자산 + 당기법인세자산 + 매각예정비유동자산
- 유동부채** = 매입채무 + 단기금융부채 + 단기사채 + 단기차입금 + 유동성장기부채 + 단기충당부채 + 당기법인세부채 + 매각예정처분자산집단부채
- 단기차입금** = 단기금융부채 + 단기사채 + 유동성장기부채
- 장기차입금** = 장기금융부채 + 사채 + 금융리스부채
- 매출원가** = 매출액 - 매출총이익

전처리 과정: 독립변수 (이상치 처리)

- 14개 재무비율에 대해 Boxplot/Histogram을 그려보았을 때 극단적인 이상치들이 나타남을 확인할 수 있음



- 재무비율 상 일반적 범위를 벗어나는 값이 곧 기업의 부도 상태 예측과 직결될 수 있을 것이라 생각되어 별도 처리하지 않고 반영하기로 결정

Feature	Outlier Count (IQR)	Total Count	Outlier Ratio (%)
설비투자효율	20509	96161	21.33
총순자산수익률	17170	96161	17.86
영업이익/총자본	12220	96161	12.71
현금흐름/총자본	11765	96161	12.23
총자본투자효율	11235	96161	11.68
유보이익/총자본	10448	96161	10.87
자본금회전율	10034	96161	10.43
금융비용/총비용	8117	96161	8.44
금융비용/부채	6948	96161	7.23
현금성자산비율	5986	96161	6.22
총부채회전율	5322	96161	5.53
총자본회전율	3443	96161	3.58
자기자본비율	2022	96161	2.1
차입금의존도	1828	96161	1.9

전처리 과정: 독립변수 (추가 결측치 처리 및 기초 통계량)

- 재무비율을 적절히 대체하여 구한 후에도 결측치가 존재하나, NA값을 누락하기 현실적인 어려움 존재
 - 1순위: 기업의 가장 가까운 데이터를 먼저 사용
 - 2순위: 일반적인 선형 보간 방식대로 평균치를 활용하여 보간하여 처리함
- 최종 데이터는 전체 96161행, Bad=1은 70행으로, 부도/파산은 흔한 사건이 아니기 때문에, 상당히 불균형한 데이터를 확인할 수 있음.

회계년	1999	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
기업수	3342	3604	3639	3698	3663	3682	3668	3697	3778	3768	3695	3659	3654	3658	3633	3660	3716	3744	3763	3763	3795	3806	3801	3796	3784	3695
Bad 개수	3	1	7	8	11	5	4	1	1	2	4	4	2	3	1	0	3	0	1	2	2	3	0	0	2	0

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

Non Time-Series Analysis

분석 방법

- 불균형 데이터로 인해 모든 기업이 $\text{Bad}=0$ 으로 예측되는 문제점을 해결하기 위해 Matched pairs-sampling 기법 활용
 - 부도/파산기업 1개당 정상기업 5개 매칭



Symbol	회계년	상장폐지년도	Bad
A	2020	2020	1
B	2020	NaN	0
C	2020	NaN	0
D	2020	NaN	0
E	2020	NaN	0
F	2020	NaN	0

- 5-Fold Cross-Validation, Accuracy/AUC 기준으로 평가
- Random Forest + AdaBoost + MLP
→ Voting ensemble로 구성

Non Time-Series Analysis

분석 방법

- Full-featured model vs. Reduced model
 - 모델 단순성을 높이기 위해, 타 변수와의 상관관계를 고려하여 $Cor > 0.8$ 인 변수는 제외하고 분석
 - 총순자산수익률(ROE) 제외



Non Time-Series Analysis

결과


	Reduced Feature Model		Full Feature Model	
	Accuracy	ROC AUC	Accuracy	ROC AUC
Random Forest	0.8779	0.8779	0.9160	0.8851
AdaBoost	0.8397	0.7982	0.8855	0.7763
MLP	0.9084	0.8144	0.8779	0.8322
Voting Ensemble	0.9237	0.9112	0.9084	0.9008

- 상당히 높은 예측력을 보이며, 특히 불균형 데이터에서 예측력을 판단할 때 쓰이는 AUC값이 낮지 않음
- Random Forest에서 AUC 가장 우수함 → 중요도 확인
- 총순자산수익률은 선행연구 결과에 따르면 중요하게 쓰이는 수익성 지표지만, 영업이익/총자본과의 관련성 때문에 삭제해도 모델 성능에 큰 영향을 미치지 않음
 - 총순자산수익률이 매우 중요한 것처럼 나타나는 까닭은 다른 중요변수인 유보이익/총자본과 상관성이 크기 때문

Non Time-Series Analysis


Full Features Model

상위 10개 중요 Feature (Random Forest 기준)



Reduced Features Model


상위 10개 중요 Feature (Random Forest 기준)



Time-Series Analysis

분석 방법

- 패널 데이터 사용으로, Pooled data 분류 방식은 사건-시간 데이터 간 관계를 반영하지 못하는 문제 발생
- 3개 년도 "연속" Sliding window로 종속변수 재처리
 - Bad=0: 79332개 (99.93%) / Bad=1: 58개 (0.07%)
- Time series split 방식으로 평가
 - Modeling Set: 1999+ k(=3) = 2002~ 2016년
 - Test set 분리: 2017~2024년
 - Case Sampling $\Rightarrow$ Each TimeSeriesSplit 도중 loss function에 weight를 부여해서 불균형 해소
- MLP+GRU(RNN계열)+TCN(시계열 분석 ver.CNN)
 - $\rightarrow$ Soft Voting(단순 확률 접근)
 - & Weighted Voting(AUC 기반 가중치) Ensemble



Time-Series Analysis

결과

	Accuracy	ROC AUC
MLP	0.9942	0.7553
GRU	0.9994	0.4985
TCN	0.9996	0.7446
Soft Voting Ensemble	0.9996	0.7526
Weighted Voting Ensemble	0.9995	0.7527

- MLP, TCN은 AUC 약 75%로 의미 있는 예측 성능 보이나, GRU는 AUC 0.5로 Random guessing 수준
- Accuracy는 99.94%로 높으나, AUC는 0.4985로 클래스 구분 불가능 → 테스트셋에 일반화 실패
- GRU는 단기 기억 구조로 LSTM보다 간단하나, 데이터 부족 + Label 불균형으로 과적합 발생함
- MLP는 단기 패턴에 강해 과적합 회피하며, TCN은 1D CNN 기반으로 병렬 연산, 장단기 패턴 모두 잘 반영함

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론



Random Survival Forest

분석방법

- Case-sampling 기반 추정은 정확한 부도/파산 확률 아님
- 패널 구조 무시하고 Pooled regression 적용 시, 관측 중단(Censored)으로 인해 편향 발생함
- 생존분석 접근법 사용 시, 부도 = 사망 / 비부도 = 생존으로 간주하여 시간 흐름에 따른 생존확률 추정 가능
- Random Survival Forest는 Random Forest의 확장 버전으로, 시점별 생존확률 추정하는 회귀 기반 모델임

Random Survival Forest

결과



- 부도기업은 시점별 생존확률 평균이 낮고, 시간이 갈수록 정상기업과 격차 커짐
- 데이터 불균형 탓에 절대적인 확률 차이는 크지 않음

- 중요 변수는 총부채회전율 > 차입금의존도 > 총순자산수익률 > 자기자본비율
- 순열 중요도 기반이라 음수 값 존재할 수 있음

Random Survival Forest

Insights

- Random Forest와 Random Survival Forest의 변수 중요도는 다르게 나타남
- Random Forest는 특정 시점의 부도 여부 예측 / RSF는 시간에 따른 생존 확률 예측함
- Random Survival Forest는 시간 누적되는 부도 리스크 반영 가능한 변수에 가중치 높게 부여됨
- 차입금의존도, 총부채회전율 등 지속적 재무 부담 지표가 Random Survival Forest에서 더 중요하게 나타남

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

Logistic Regression with Lasso

분석 방법

- 선행연구의 결과를 따르지 않고 재무제표에서 어떤 요인이 중요한지 보기 위해 전체 재무변수를 넣어서 LASSO 및 Ridge Regression을 진행함

전체 데이터 27,309,724 중 1,892,872가 NA

각 기업에 대한 데이터 수의 형평성을 위해 각 기업별 최근 연도(파산기업의 경우 파산연도)만 추출

모든 0을 NA로 전환

NA 40% 이상 열 삭제

나머지 Median 보간

Multicollinearity 제거하기 위해 Correlation 0.9 이상 Column 제거


Case sampling 시행 (파산 기업 수 70에 맞추어 70:70으로 추출) 후 Scaling

Train/Test 7:3으로 나누어 Logistic Regression에 L1 Penalty term 더해 적합 (C=54.62)

Logistic Regression with Lasso

결과

제외 변수: 총자산, 유동자산, 총금융자산, 총차입부채, 순차입부채, 계속사업법인세비용, 이자비용, 외환손실, 현금유입이없는수익의차감, 영업활동으로인한자산부채의변동



c=0.5


	실제 1	실제 0
예측 1	18	3
예측 0	3	18

Accurary = 0.786

c=0.8

	실제 1	실제 0
예측 1	14	7
예측 0	2	19


Accurary = 0.857



ROC-AUC Score = 0.914

Logistic Regression with Ridge

결과

**c=0.5**


	실제 1	실제 0
예측 1	14	7
예측 0	2	19

Accuracy = 0.786

c=0.8

	실제 1	실제 0
예측 1	17	4
예측 0	4	17

Accuracy = 0.810



ROC-AUC Score = 0.887

Table of Contents

1. 서론

2. 데이터 소개

3. 전처리 과정

4. 부도여부 예측

5. 부도확률 예측

6. 전체 Feature 분석

7. 결론

결과 요약

Insights

- 복잡한 모델이 항상 더 좋은 건 아님
 - 단순히 예측력만 보면 딥러닝보다 Random Forest가 더 나은 성능 보임
 - 주어진 데이터의 부족 및 불균형으로 인하여 성능 감소 (시계열의 경우 연속 Sliding window 로 인해 Sample 수 감소 및 불균형 심화)
 - 예측만 목표라면 단순 모델로도 충분함
 - 단, 시계열적 Inference 필요 시에는 패널 구조를 반영한 복잡 모델 필수
- 단발성 부도 예측 vs 생존기간 기반 부도 확률 예측은 중요한 재무지표가 다름
 - 생존기간 고려 시, 활동성 지표(예: 총부채회전율)가 더 중요해질 수 있음
- 선행연구 기반 재무비율도 일정 부분 타당함 (예: LASSO 결과 참고)
 - 하지만 모든 지표를 쓸 필요는 없음
 - RSF에선 음수 중요도 발생 → 일부 변수는 정보 기여도 낮거나 중복 가능성 있음

프로젝트 합의 및 활용 방안

정부

투자자/은행

신용평가
등급
예측 및 평가

기업 법정 관리, 회생 절차 등 공공기관의 의사결정 당위성 부여 가능

기업에게 투자/대출 시 원금 손실의 위험성 최소화

- Dataguide 활용
 - 기업어음 신용등급 보유 기업: 522개
 - 회사채 신용등급 보유 기업: 808개
- 신용등급을 점수로 변환하여 회귀분석 수행
 - 예: AAA = 22점, AA+ = 21점 등

```
Call:
lm(formula = as.formula(paste0("rating_score ~ survivalrate_",
i)), data = credit_bond)

Residuals:
    Min       1Q   Median       3Q      Max
-14.1882  -2.1882   0.8118   2.8118  23.8245

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    -311.3      40.6    -7.668 1.98e-14 ***
survivalrate_3    326.5      40.6     8.041 1.04e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.245 on 7240 degrees of freedom
(결측으로 인하여 80개의 관측치가 삭제되었습니다.)
Multiple R-squared:  0.008851, Adjusted R-squared:  0.008714
F-statistic: 64.65 on 1 and 7240 DF,  p-value: 1.037e-15
```

기업어음신용등급

```
Call:
lm(formula = rating_score ~ survivalrate_3, data = credit_cp)

Residuals:
    Min       1Q   Median       3Q      Max
-7.9954  -0.9954   1.0046   1.0046   4.8843

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    -668.42      67.58  -9.891 <2e-16 ***
survivalrate_3    677.41      67.58   10.023 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.546 on 2920 degrees of freedom
(결측으로 인하여 1598개의 관측치가 삭제되었습니다.)
Multiple R-squared:  0.03326, Adjusted R-squared:  0.03293
F-statistic: 100.5 on 1 and 2920 DF,  p-value: < 2.2e-16
```

회사채신용등급

- 생존확률이 높을수록 신용등급도 높게 나타남
- 기업어음 예시: 생존확률 0.0014 증가 → 신용등급 1등급 상승
- 부도확률 기반 예측 모델이 실제 신용등급 반영 가능성 입증됨

- 미래 신용등급 미부여 기업에 대한 등급 예측 도구로 사용 가능
- 은행 대출 심사, 투자 판단 등 실무적 활용성 높음

E.O.D

Appendix: 선행연구 (전통적 부도 예측)

Altman's Z-score (1968)

! 기업이 2년 내에 파산할 것인지를 예측할 수 있는 모형

- 모델: $Z = 1.2X_1 + 1.4X_2 + 3.3X_3 + 0.6X_4 + 1.0X_5$
 - X_1 : 순운전자본/총자산
 - 순운전자본 = 유동자산 - 유동부채
 - X_2 : 이익잉여금/총자산
 - X_3 : 영업이익(EBIT)/총자산
 - X_4 : 자본의 시장가치/부채의 장부가치
 - X_5 : 매출액/총자산 $\times 1$
- 평가기준
 - $Z > 2.99$ - "safe" zone
 - $1.81 < Z < 2.99$ - "grey" zone
 - $Z < 1.81$ - "distress" zone

Ohlson's O-score (1980)

! Altman의 Z-score의 대안으로 떠오른 9개의 재무비율 모형

- 모델: 하이라이트 표시한 지표는 Altman과 동일

$$T = -1.32 - 0.407 \log(TA_t / GNP) + 6.03 \frac{TL_t}{TA_t} - 1.43 \frac{WC_t}{TA_t} + 0.0757 \frac{CL_t}{CA_t} - 1.72X - 2.37 \frac{NI_t}{TA_t} - 1.83 \frac{FFO_t}{TL_t} + 0.285Y - 0.521 \frac{NI_t - NI_{t-1}}{|NI_t| + |NI_{t-1}|}$$

- $SIZE = \log(\text{총자산}/GNP \text{ 물가지수})$
- $TL/TA = \text{총부채}/\text{총자산}$
- $WC/TA = \text{운전자본}/\text{총자산} \rightarrow X_1 \text{과 동일}$
- $CL/CA = \text{유동부채}/\text{유동자산}$
- $NI/TA = \text{순이익}/\text{총자산} \rightarrow X_3 \text{와 거의 동일 (세금 및 이자 비용 제외)}$
- $FFO/TL = \text{영업활동 현금흐름}/\text{총부채}$
- 평가기준
 - $T \geq 0.5$ - 파산 위험 높음
 - $T \rightarrow -1.81$ 에 가까울수록 재무적으로 건전

Appendix: 선행연구 (국내 기업 연구)

639 경영학연구 제43권 제3호 2014년 6월(pp. 639~669)

재무비율을 이용한 부도예측에 대한 연구: 한국의 외부감사대상기업을 대상으로*

박종원(교신저자)
서울시립대학교 경영대학 교수
(jarkwon@slu.ac.kr)
안성만(주저자)
농협은행 아산점장
(asem1230@nonghyusan.com)

본 연구는 한국시장의 외부감사대상기업을 대상으로 재무비율을 이용한 부도예측모형을 개발하고 모형의 정확도와 변별력을 검증하였다. 상장기업들을 대상으로 이루어진 선행연구와 달리 외부감사대상기업 전체를 대상으로 재무비율을 이용한 부도예측 모형을 구축하고 그 적용가능성을 살펴보았다는 점에서, 기업의 부실을 설명해줄 수 있는 변수를 파악하기 위해 구성가능한 117개의 대량의 재무비율을 사용하였다는 점에서 기존연구와 차별화된 특징을 갖는다. 모형의 변별력을 파악하기 위해 AUROC, AR, K-S 통계량 등을 사용하였다. 결산연도기준으로 2003년~2006년의 외부감사대상기업들의 데이터를 이용하여 다변량 로짓분석을 이용한 결과 금융비용대부채비율, 자기자본비율, 차입금의존도, 현금성자산비율, 총부채회전율, 영업이익대총자산비율, 총자본투자비율, 기업규모, 건설업 더미, 제조업더미 등 17개의 변수가 부도예측모형을 구성하는 변수로 선택되었다. 추정된 모형의 분류 정확도(concordant ratio)는 82%로 나타났으며, 부도예측에 대한 모형의 변별력 지표인 AUROC값은 85%, K-S 통계량은 55%로 매우 양호하게 나타났다. 이러한 결과는 데이터에 존재하는 극단치와 결측치에 영향을 받지 않는 결과이며, 매 연도별 분석에서도 큰 차이를 보이지 않아 시계열적으로도 강건한 결과이다. 이는 본 연구에서 구축한 모형이 한국시장의 외부감사대상기업의 부도예측에 유용하게 사용될 수 있음을 의미한다.

주제어: 외부감사대상기업, 부도예측, 재무비율, 다변량 로짓분석, AUROC, K-S통계량

I. 서론

한국 경제에 큰 타격을 준 1997년의 외환위기 이후 기업의 부도위험을 정확하게 판단하기 위한 노력이 지속적으로 이루어져왔으며, 2008년 미국시장의 서브프라임모기지 사태로 촉발된 세계금융위기 이후 그 중요성은 더욱 강조되고 있다. 기업의 부도위험을 정확하게 평가할 수 있다면 막대한 사회·경제적 손실을 야기하는 기업의 부도를 사전에 예측할 수 있고, 경영정책의 변화와 재무구조개선을 통해 기업

경영을 정상화시키는 동기를 제공할 수 있다. 또한 자발적인 청산의 경우에도 불필요한 자원의 낭비를 줄이고 자원의 효율적 배분을 가능케 함으로써 관련 비용을 최소화 시킬 수 있다는 점에서 부도예측을 위한 모형의 개발과 평가는 중요한 의미를 갖는다. 재무제표로부터 손쉽게 얻을 수 있는 재무비율은 기업부실을 예측하는 모형의 투입변수로 곧잘 활용된다. 특히 외부감사를 통해 신뢰성이 검증된 재무제표를 얻을 수 있는 외부감사대상기업(이하, 외감기업)의 경우 재무비율을 이용한 부도예측모형은 모형 구축의 용이성과 비용 측면에서 또 재무제표정보가

최초투고일: 2014. 2. 3 게재확정일: 2014. 3. 24
* 이 논문은 2013년도 서울시립대학교 교내연구비 지원을 받아 작성되었으며, 두 번째 저자의 서울시립대학교 석사학위논문 내용 일부를 수정, 보완하여 발전시킨 것입니다.

재무비율을 이용한 부도예측에 대한 연구: 한국의 외부감사대상기업을 대상으로

〈표 5〉다변량 로짓회귀분석 추정결과

변수코드	범주	변수	가중치	표준오차	Wald통계량	p-value
Intercept			2.8668	1.6644	2.9666	0.0850
FR010	부채상환능력	금융비용대부채비율	0.3432	0.0462	55.143	< 0.0001
FR011	비용구조	금융비용대총자산비율	-0.1061	0.0429	6.1200	0.0134
FR030	생산성	설비투자효율	0.00004	0.0000	5.6308	0.0171
FR042	현금흐름	현금흐름대총자산비율	0.0124	0.0032	14.910	0.0001
FR046	수익성	영업이익대총자산비율	-0.0138	0.0063	4.7516	0.0293
FR065	안정성	유보이익대총자산비율	0.0204	0.0049	16.899	< 0.0001
FR076	안정성	자기자본비율	-0.0288	0.0058	24.298	< 0.0001
FR080	활동성	자본회전율	-0.0159	0.0059	7.1260	0.0076
FR090	안정성	차입금의존도	-0.0169	0.0036	21.809	< 0.0001
FR092	활동성	총부채회전율	-1.4934	0.2303	42.037	< 0.0001
FR095	생산성	총자본투자효율	-0.0561	0.0089	39.837	< 0.0001
FR096	활동성	총자본회전율	1.4723	0.2607	31.893	< 0.0001
FR097	수익성	총자산순이익률	0.0401	0.0102	15.555	< 0.0001
FR106	유동성	현금성자산비율	-0.0353	0.0079	19.809	< 0.0001
dummy1	산업	제조업	1.4034	0.4006	12.275	0.0005
dummy2	산업	건설업	2.4088	0.4684	26.464	< 0.0001
ln(asset)	규모	총자산	-0.3836	0.0911	17.736	< 0.0001

〈표 6〉에 모형에 포함된 각 재무비율들을 이용하여 각기 구한 오즈(odds)를 나타내었다.

〈표 6〉의 추정결과를 보면, 각 변수들이 부도확률에 미치는 개별적인 영향을 파악할 수 있다. 즉, Odds = 부도확률/(1-부도확률)이므로 결국 부도확률 대 정상확률의 비율이다. 따라서 〈표 6〉의 각 변수들의 Odds는 해당변수가 1단위 증가할 때 부도확률대정상확률의 비율이 몇 배 증가하는 가를 나타낸다. Odds가 1보다 작으면 정상확률에 비해 부도확률이 감소한다는 의미를 나타내고, 1이면 변화없다는 의미를 나타내며, 1보다 크면 정상일 확률보다 부도일 확률이 증가한다는 의미를 나타낸다. 또한 신뢰구간이 1을 포함하고 있으면 통계적 유의성이 없는 것이

고, 1에서 벗어나면 유의성이 있다고 해석할 수 있다. 〈표 6〉에서 부도확률에 의미있는 영향을 미치는 대표적인 변수는 금융비용대부채비율, 총부채회전율, 총자본회전율, 총자산, 그리고 제조업과 건설업 더미변수이다. 금융비용대 부채비율이 한 단위 증가하는 경우 부도확률대정상확률의 비율은 약 1.4배 증가한다. 이는 모집단의 부도확률이 10%라면 금융비용대부채비율이 1% 증가하는 경우 부도확률이 4.44% 증가함을 의미한다. 반면, 총부채회전율의 Odds는 0.225의 값을 갖는다. 이는 총부채회전율이 1% 증가하는 경우 부도확률대정상확률의 비율이 0.225배로 감소함을 나타낸다. 총자산과 유보이익 대총자산비율, 총자산순이익률은 증가시 부도위험이